Conditional PED-ANOVA: Hyperparameter Importance in Hierarchical & Dynamic Search Spaces

階層的・動的探索空間におけるハイパーパラメータ重要度

Kaito Baba[1,2], Yoshihiko Ozaki[1], Shuhei Watanabe[3]

[1]Preferred Networks, Inc. [2]The University of Tokyo [3]SB Intuitions Corp.



Accepted to The 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD 2026)

01. 背景と貢献
02. 事前知識
03. 提案手法
04. 合成問題での評価
05. 実問題ベンチマーク

SECTION 01

背景と貢献

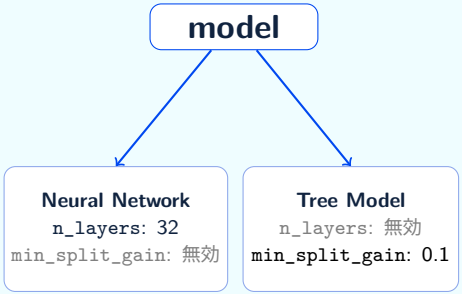
Motivation & Contributions

条件付き（階層的・動的）探索空間

ハイパーパラメータ最適化で頻出

- 上流の選択が、下流パラメータの定義を制御する
- 有効・無効が上流の選択で切り替わる
- 定義域や候補集合も上流の選択によって変化する

例：モデル選択



探索空間は単一の直積空間ではなく、複数の条件分岐から構成される

ハイパーパラメータ重要度（HPI）

HPI の役割

- 各ハイパーパラメータが性能に与える影響を定量化
- 重要・無関係・冗長な設計選択を特定
- 探索空間の解釈・縮約・再設計に活用

PED-ANOVA (Watanabe et al., 2023)

- ✓ 高性能領域に限定した局所 HPI を計算
- ✓ f-ANOVA (Hutter et al., 2014) より圧倒的に高速
- × 固定された無条件探索空間を仮定

ハイパーパラメータ重要度（HPI）

HPI の役割

- 各ハイパーパラメータが性能に与える影響を定量化
- 重要な無条件探索空間の特定
- 探索空間の解釈・縮約・再利用に活用

PED-ANOVA (Watanabe et al., 2023)

- ✓ 高性能領域に限定した局所 HPI を計算
- ✓ 条件付き探索空間の大幅な変更に対応
- × 固定された無条件探索空間を仮定

条件付き探索空間を原理的に扱える HPI推定法がない

本研究の貢献

本研究の貢献

1 既存の局所 HPI における上流の分岐効果の漏れを特定

従属パラメータへの誤配分により、無効なパラメータにも重要度が付くことを理論・実験で示す

本研究の貢献

1 既存の局所 HPI における上流の分岐効果の漏れを特定

従属パラメータへの誤配分により、無効なパラメータにも重要度が付くことを理論・実験で示す

2 条件付き局所 HPI（Conditional Local HPI）を定義

上流の選択による交絡を除き、各パラメータ自身の効果を測る

本研究の貢献

1 既存の局所 HPI における上流の分岐効果の漏れを特定

従属パラメータへの誤配分により、無効なパラメータにも重要度が付くことを理論・実験で示す

2 条件付き局所 HPI（Conditional Local HPI）を定義

上流の選択による交絡を除き、各パラメータ自身の効果を測る

3 condPED-ANOVA を導出

PED-ANOVA の計算効率を維持しつつ、条件付き局所 HPI の閉形式推定量を導出する

本研究の貢献

1 既存の局所 HPI における上流の分岐効果の漏れを特定

従属パラメータへの誤配分により、無効なパラメータにも重要度が付くことを理論・実験で示す

2 条件付き局所 HPI（Conditional Local HPI）を定義

上流の選択による交絡を除き、各パラメータ自身の効果を測る

3 condPED-ANOVA を導出

PED-ANOVA の計算効率を維持しつつ、条件付き局所 HPI の閉形式推定量を導出する

4 合成問題・実問題で検証

既存手法では捉えられない、条件付き探索空間の構造を正確に捉えた HPI を示す

Optuna & Rustunaでの利用

- ✓ 条件付き探索空間を標準でサポート
- ✓ 従来デフォルトの f-ANOVA より圧倒的に高速
- ✓ Optuna 標準の最小限の依存関係だけで動作

```python
import optuna

def objective(trial: optuna.trial.Trial) -> float:
    model = trial.suggest_categorical("model", ["nn", "tree"])

    if model == "nn":
        n_layers = trial.suggest_int("n_layers", 1, 5)
        return train_nn(n_layers)
    else:
        min_split_gain = trial.suggest_float("min_split_gain", 0.0,
        1.0)
        return train_tree(min_split_gain)

sampler = optuna.samplers.RandomSampler(seed=42)
study = optuna.create_study(sampler=sampler, direction="minimize")
study.optimize(objective, n_trials=200)

importances = optuna.importance.get_param_importances(study)
```

Optuna & Rustunaでの利用

- ✓ 条件付き探索空間を標準でサポート
- ✓ 任意のコールバックやCLIツールより圧倒的に高速
- ✓ Optuna標準の最小限の依存関係だけで動作

```python
import optuna

def objective(trial: optuna.trial.Trial) -> float:
    model = trial.suggest_categorical("model", ["nn", "tree"])
    if model == "nn":
        n_layers = trial.suggest_int("n_layers", 1, 5)
        return train_nn(n_layers)
    else:
        max_depth = trial.suggest_int("max_depth", 2, 32, log=True)
        min_split_gain = trial.suggest_float("min_split_gain", 0.0,
        return train_tree(max_depth, min_split_gain)

sampler = optuna.samplers.RandomSampler(seed=42)
study = optuna.create_study(sampler=sampler, direction="minimize")
study.optimize(objective, n_trials=200)
```

Optuna v5 & Rustunaデフォルトのハイパーパラメータ重要度推定手法に

機械学習分野のトップカンファレンスの1つである KDD 2026 に採択

01. 背景と貢献
02. 事前知識
03. 提案手法
04. 合成問題での評価
05. 実問題ベンチマーク

SECTION 02

事前知識

Preliminaries

Local HPI：上位 γ 領域内の重要度

- **目的関数：** $f\colon \mathcal{X} \to \mathbb{R}$ の最小化　$(\mathcal{X} \coloneqq \mathcal{X}^{(1)} \times \cdots \times \mathcal{X}^{(D)})$
- **上位 γ 集合：** 評価済みデータの上位 γ を達成する集合

$$\mathcal{X}_\gamma \coloneqq \{\boldsymbol{x} \mid f(\boldsymbol{x}) \le f_\gamma\}, \qquad f_\gamma：\text{経験的な上位 } \gamma \text{ 分位点}$$

- **局所周辺平均 (local marginal mean)：**
  $x^{(d)}$ を固定し、$\mathcal{X}_\gamma$ 内で他の変数について平均

$$f_\gamma^{(d)}(x^{(d)}) \coloneqq \mathbb{E}\Big[f(\boldsymbol{X}) \mid \boldsymbol{X} \in \mathcal{X}_\gamma,\ X^{(d)} = x^{(d)}\Big]$$

- **局所周辺分散 (local marginal variance)：**
  $x^{(d)}$ に沿った局所周辺平均のばらつき

$$v_\gamma^{(d)} \coloneqq \mathrm{Var}\Big[f_\gamma^{(d)}(X^{(d)}) \mid \boldsymbol{X} \in \mathcal{X}_\gamma\Big], \qquad \boxed{\text{Local HPI} \coloneqq \frac{v_\gamma^{(d)}}{\sum_{d'=1}^{D} v_\gamma^{(d')}}}$$

PED-ANOVA：上位 γ' 領域へ入る重要度

- $\mathcal{X}_{\gamma'} \subset \mathcal{X}_{\gamma}$（$0 < \gamma' < \gamma \leq 1$）を考える (e.g., $\gamma' = 0.1$, $\gamma = 0.9$)
- $x^{(d)}$ の周辺分布を 2 つの領域で比較する（各分布は KDE で推定）：

$$p_{\gamma'}^{(d)} \text{ in } \mathcal{X}_{\gamma'} \qquad \text{vs.} \qquad p_{\gamma}^{(d)} \text{ in } \mathcal{X}_{\gamma}$$

- 二値目的関数 $b_{\gamma'}(\boldsymbol{x}) = \mathbf{1}\{\boldsymbol{x} \in \mathcal{X}_{\gamma'}\}$ に対して局所周辺分散が閉形式になる：

$$\boxed{v_{\gamma}^{(d)} = \left(\frac{\gamma'}{\gamma}\right)^2 D_{\mathrm{PE}}\left(p_{\gamma'}^{(d)} \middle\| p_{\gamma}^{(d)}\right)}, \qquad D_{\mathrm{PE}}(p\|q) := \int \left(\frac{p(x)}{q(x)} - 1\right)^2 q(x)\,\mathrm{d}x$$

上位 γ' 領域に入るために、$x^{(d)}$ の分布がどれだけ変化するかを測る

01. 背景と貢献
02. 事前知識
03. 提案手法
04. 合成問題での評価
05. 実問題ベンチマーク

SECTION 03

提案手法

condPED-ANOVA

条件付きパラメータをレジームで表現

レジーム (regime)

- 上流の選択により、$x^{(d)}$ が属するレジーム $i^{(d)} \in \{1, \ldots, K^{(d)}\}$ が決まる
- レジーム固有の定義域：$x^{(d)} \in \mathcal{Z}_i^{(d)}$
- $\mathcal{Z}_i^{(d)}$ はレジームごとに異なってよい
- 無効なレジームでは $\mathcal{Z}_i^{(d)} = \{\perp\}$

例：モデル選択

$x^{(0)} \in \{\texttt{neural}, \texttt{tree}\}$
$x^{(1)}$: `n_layers`
$x^{(2)}$: `min_split_gain`

の場合

$$x^{(0)} = \texttt{neural} \Rightarrow \begin{cases} x^{(1)} \in \{1, \ldots, L_{\max}\} \\ x^{(2)} = \perp \end{cases}$$

$$x^{(0)} = \texttt{tree} \Rightarrow \begin{cases} x^{(1)} = \perp \\ x^{(2)} \in [0, 1] \end{cases}$$

Conditional Local HPI

局所周辺分散を 2 つの成分に分解

局所周辺分散 (Local marginal variance)

$$v_\gamma^{(d)} = \underbrace{\mathbb{E}_{I^{(d)}}\left[\mathrm{Var}_{Z^{(d)}}(g_\gamma^{(d)} \mid I^{(d)})\right]}_{\text{レジーム内局所周辺分散 (Within-regime local marginal variance)}} + \underbrace{\mathrm{Var}_{I^{(d)}}\left[\mathbb{E}_{Z^{(d)}}(g_\gamma^{(d)} \mid I^{(d)})\right]}_{\text{レジーム間局所周辺分散 (Inter-regime local marginal variance)}}$$

$v_{\gamma,\mathrm{within}}^{(d)}$: パラメータ自身の効果

上流の分岐効果

レジーム内分散だけを使い、上流の分岐効果を除外する

$$\text{Conditional Local HPI} \coloneqq \frac{v_{\gamma,\mathrm{within}}^{(d)}}{\sum_{d'=1}^{D} v_{\gamma,\mathrm{within}}^{(d')}}$$

condPED-ANOVA：閉形式推定量

- レジームの出現確率：

$$\alpha_i^{(d)} := \Pr(I^{(d)} = i \mid X \in \mathcal{X}_{\gamma'}), \qquad \beta_i^{(d)} := \Pr(I^{(d)} = i \mid X \in \mathcal{X}_{\gamma})$$

- 二値目的関数 $b_{\gamma'}$ に対するレジーム内局所周辺分散：

$$v_{\gamma,\text{within}}^{(d)} = \left(\frac{\gamma'}{\gamma}\right)^2 \sum_{i=1}^{K^{(d)}} \frac{(\alpha_i^{(d)})^2}{\beta_i^{(d)}} D_{\text{PE}}\left(p_{\gamma',i}^{(d)} \middle\| p_{\gamma,i}^{(d)}\right)$$

- 無効なレジーム ($\mathcal{Z}_i^{(d)} = \{\perp\}$) は和に寄与しない
- 条件分岐なし ($K^{(d)} = 1$) なら元の PED-ANOVA に一致

PED-ANOVA の計算効率を維持しつつ、条件付き探索空間を正しく扱う

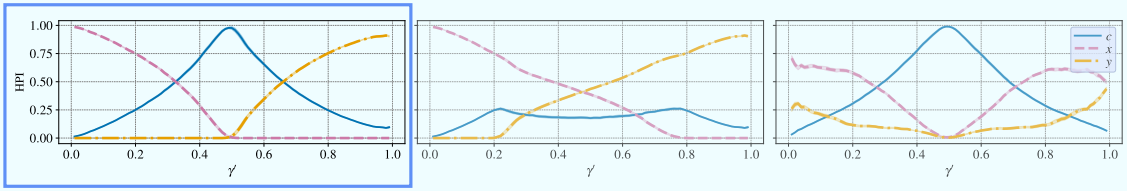
01. 背景と貢献
02. 事前知識
03. 提案手法
04. 合成問題での評価
05. 実問題ベンチマーク

SECTION 04

合成問題での評価

Synthetic Experiments

合成問題：condPED-ANOVA の挙動 (1/3)



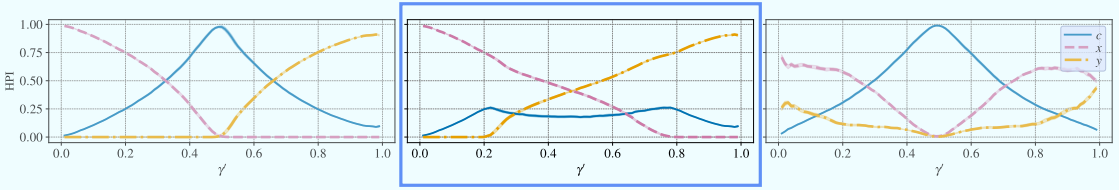
条件付き有効化（排他的な分岐）

- $\gamma' \simeq 0.5$ で分岐変数 c の HPI が高い
- $\gamma' \lesssim 0.5$ で x が重要、無効な y はほぼ 0

$$f(c,x,y) = \begin{cases} x, & \text{if } c < 0.5, \\ y, & \text{if } c \geq 0.5, \end{cases}$$

$$c \in [0,1],$$
$$x \in [-5,-2],$$
$$y \in [2,5]$$

合成問題：condPED-ANOVA の挙動 (2/3)



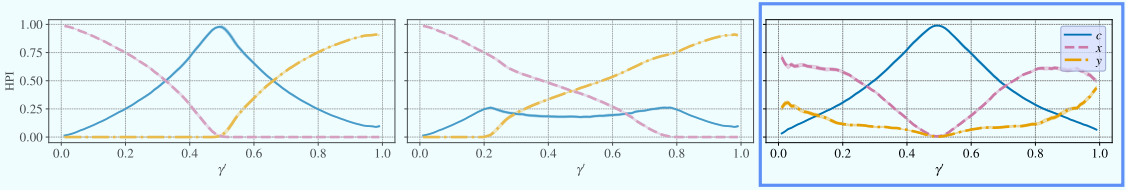
条件付き有効化（重なりのある分岐）

- $0.2 \lesssim \gamma' \lesssim 0.8$ で x, y 両方の HPI が存在
- $\gamma' \lesssim 0.2$ で x が重要、無効な y はほぼ 0

$$f(c,x,y) = \begin{cases} x, & \text{if } c < 0.5, \\ y, & \text{if } c \geq 0.5, \end{cases}$$

$$c \in [0,1],$$
$$x \in [-5,2],$$
$$y \in [-2,5]$$

合成問題：condPED-ANOVA の挙動 (3/3)



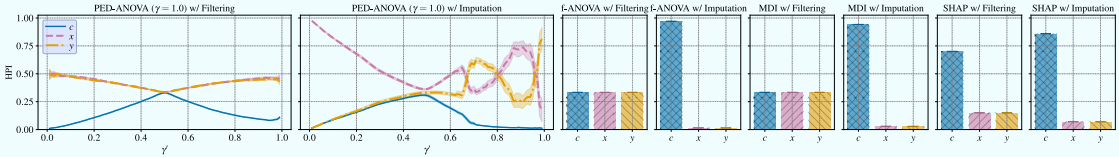
分岐依存の定義域

- $\gamma' \simeq 0.5$ で分岐変数 c の HPI が高い
- 定義域が広い x は y より HPI が高い

$$f(c, x, y) = x + y$$

$$\begin{cases} x \in [-7, -2], y \in [-5, -2] & \text{if } c < 0.5, \\ x \in [2, 7], y \in [2, 5], & \text{if } c \geq 0.5, \end{cases}$$

既存HPI推定法との比較



比較対象と素朴な拡張

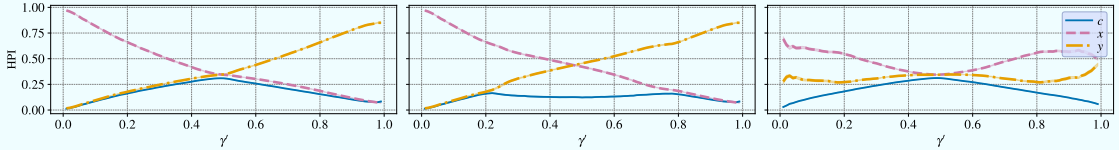
- PED-ANOVA、f-ANOVA、MDI (Louppe et al., 2013)、SHAP (Lundberg & Lee, 2017)
- 無効パラメータをフィルタまたは補完
- 分岐依存定義域を統一定義域へ拡張

問題点

- フィルタすると全空間での効果を隠し、x と y を混同
- 欠損値補完は人工的な値を導入し、HPI を不安定化
- どちらも c を過小評価し、無効パラメータに HPI を配分

Ablation 1：Conditional Local HPI の必要性

変更点： $v^{(d)}_{\gamma,\mathrm{within}}$ の代わりに、レジーム内/間の両方を含む局所周辺分散 $v^{(d)}_{\gamma}$ を使用



× $\gamma' \simeq 0.5$ 付近で、分岐選択が重要にもかかわらず c を過小評価

× 無効な x または y に非ゼロの HPI：c の効果が従属変数へ漏れる

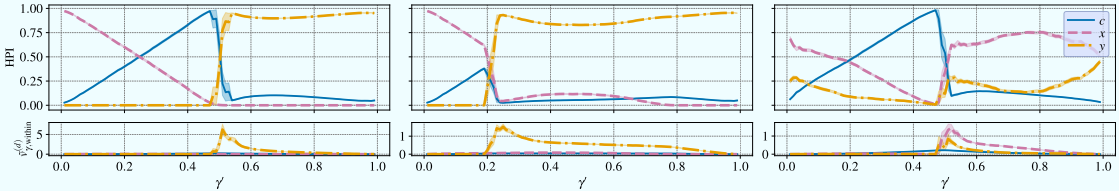
従来の局所 HPI では、パラメータ自身の効果と上流の分岐効果を分離できない

局所周辺分散 $v^{(d)}_{\gamma}$ ＝ レジーム内局所周辺分散 $\mathbb{E}_{I^{(d)}}\left[\mathrm{Var}_{Z^{(d)}}(g^{(d)}_{\gamma} \mid I^{(d)})\right]$ ＋ レジーム間局所周辺分散 $\mathrm{Var}_{I^{(d)}}\left[\mathbb{E}_{Z^{(d)}}(g^{(d)}_{\gamma} \mid I^{(d)})\right]$

$v^{(d)}_{\gamma,\mathrm{within}}$：パラメータ自身の効果　　上流の分岐効果

Ablation 2：レジーム重みの必要性

変更点：重み $(\alpha_i^{(d)})^2/\beta_i^{(d)}$ を除き、レジーム内 Pearson ダイバージェンスを単純に合計



× レジームが切り替わる境界で重要度が不連続にジャンプ

× 目的関数が持つ Top–Bottom 間の対称性が崩れる

レジームの出現頻度を正しく考慮することが必要

$$v^{(d)}_{\gamma,\mathrm{within}} = \left(\frac{\gamma'}{\gamma}\right)^2 \sum_{i=1}^{K^{(d)}} \cancel{\frac{(\alpha_i^{(d)})^2}{\beta_i^{(d)}}} D_{\mathrm{PE}}\left(p^{(d)}_{\gamma',i} \middle\| p^{(d)}_{\gamma,i}\right)$$

01. 背景と貢献
02. 事前知識
03. 提案手法
04. 合成問題での評価
05. 実問題ベンチマーク

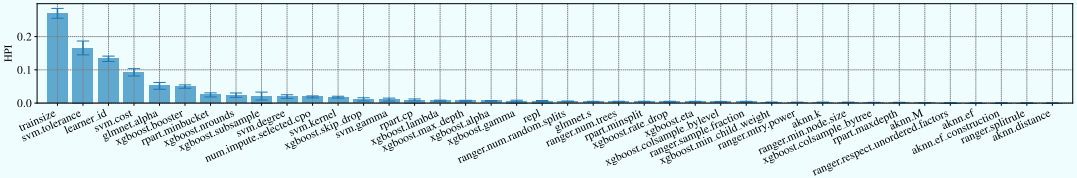
SECTION 05

実問題ベンチマーク

Real-World Benchmark

YAHPO Gym：実験設定とHPI

設定： `rbv2_super`、6 種類からモデル選択、$N = 1{,}000$、$\gamma = 1.0$、$\gamma' = 0.1$



- ✓ `trainsize`、`learner_id`、SVM/XGBoost 固有パラメータが高い HPI を得る
- ✓ 性能を上げるうえで重要と経験的に知られるパラメータを高く評価
  - XGBoost：`booster`, `nrounds`, `subsample`
  - SVM：`cost`

モデルごとの精度との対応

各モデルごとの実際の精度

モデル	最小	平均	最大
svm	0.727 ± 0.004	0.796 ± 0.001	**0.926 ± 0.005**
xgboost	0.591 ± 0.011	0.765 ± 0.001	0.853 ± 0.004
rpart	0.736 ± 0.001	0.774 ± 0.001	0.846 ± 0.003
glmnet	0.731 ± 0.001	0.778 ± 0.001	0.842 ± 0.003
ranger	0.738 ± 0.002	0.777 ± 0.000	0.815 ± 0.002
aknn	0.174 ± 0.001	0.591 ± 0.006	0.809 ± 0.002

- ✓ 学習器の性能順位と、対応する固有パラメータの HPI 順位がおおむね一致
- ✓ 特に最大精度の高い SVM/XGBoost について、固有パラメータを高く評価

既存手法との比較：モデル単位の相関

各モデルの最大精度と、そのモデル固有パラメータ中の最大 HPI との相関

ID	condPED-ANOVA (Ours)	PED-ANOVA w/ Filtering	PED-ANOVA w/ Imputation	f-ANOVA w/ Filtering	f-ANOVA w/ Imputation	MDI w/ Filtering	MDI w/ Imputation	SHAP w/ Filtering	SHAP w/ Imputation
1053	**0.98**	0.92	0.93	0.19	−0.46	−0.14	−0.46	−0.44	−0.44
1457	**0.76**	−0.14	0.61	−0.60	0.70	−0.38	0.60	0.50	0.51
1063	**0.62**	0.22	0.51	−0.08	−0.72	−0.45	−0.71	−0.65	−0.59
1479	0.87	−0.03	0.72	0.72	0.90	0.73	0.91	0.96	**0.98**
15	**0.59**	−0.11	0.54	0.18	0.24	−0.02	0.21	0.14	0.20
1468	**0.80**	0.13	0.55	−0.27	0.49	−0.19	0.33	0.20	0.30
Mean ± SE	**0.77 ± 0.05**	0.16 ± 0.15	0.64 ± 0.06	0.02 ± 0.17	0.19 ± 0.24	−0.07 ± 0.16	0.15 ± 0.23	0.12 ± 0.22	0.16 ± 0.22

- ✓ ほぼすべてのデータセットで最も高い相関
- ✓ 既存手法で見られる不安定な負の相関がない

まとめ

- 条件付き探索空間では、既存の局所 HPI は**上流の分岐効果**を従属パラメータへ誤配分
- **条件付き局所 HPI** はレジーム内分散のみを使い、パラメータ自身の効果を測る
- 提案手法は PED-ANOVA の効率性を維持しつつ条件付き局所 HPI を閉形式で推定
- 合成問題・実問題ベンチマークの双方で、素朴な拡張より妥当かつ安定な HPI を得る
- Optuna v5 及び Rustuna のデフォルト重要度評価手法として利用可能
- 機械学習分野のトップカンファレンスの 1 つである KDD 2026 に採択

Our Paper

Our Code

Blog Post (ja)

参考文献

Hutter, F., Hoos, H., and Leyton-Brown, K. An efficient approach for assessing hyperparameter importance. In *Proceedings of the 31st International Conference on Machine Learning*, pp. 754–762. PMLR, 2014.

Louppe, G., Wehenkel, L., Sutera, A., and Geurts, P. Understanding variable importances in forests of randomized trees. In *Advances in Neural Information Processing Systems*, volume 26, 2013.

Lundberg, S. M. and Lee, S.-I. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

Pfisterer, F., Schneider, L., Moosbauer, J., Binder, M., and Bischl, B. YAHPO Gym - an efficient multi-objective multi-fidelity benchmark for hyperparameter optimization. In *Proceedings of the First International Conference on Automated Machine Learning*, volume 188, pp. 3/1–39. PMLR, 2022.

Watanabe, S., Bansal, A., and Hutter, F. PED-ANOVA: Efficiently quantifying hyperparameter importance in arbitrary subspaces. In *Proceedings of the 32nd International Joint Conference on Artificial Intelligence*, pp. 4389–4396, 2023.